队伍编号	MCB250XXXX
赛道	A

啤酒感官预测与受约束风格迁移

摘 要

针对化学测量、专业感官评分与消费者评论具有不同数据尺度和采样机制的问题，本文在 250 款啤酒、231 个化学与理化特征及 50 个感官响应上，构建带有证据审计的预测、归因、生成和多目标决策流程。外部啤酒评论数据只作风格趋势对照，不充当化学测量或专业品评标签。

针对问题一，采用折内缺失及重复底值状态处理，引入秩正态偏最小二乘与树模型候选。外层三折重复三次评价完整选型过程，内层三折选择模型。嵌套程序的完整折外预测平均 R^2为 0.2113、MAE 为 0.3547；同划分固定随机森林的 R^2为 0.1966。输出 0 至 6 相对等级，但不宣称恢复原始绝对评分。

针对问题二，保留固定共表达网络的原三方法结果作为对照，新增风格残差秩关联选择器及 100 次无放回近似分层半样本诊断。150 个候选中有 4 项频率达到 0.8；通过未见标签的验证特征近邻供体估计条件置换重要性，明确相关变量、候选选择规则及固定图的局限。

针对问题三，复用已训练条件 VAE 比较三种采样方式，另对条件收缩高斯及两个经验基准进行分层留出分布检验。尺度审计发现 70 列有标定对照，其中 38 列在可比正值行中一致、32 列存在局部不一致。迁移将已核实正浓度约束和分析尺度非恶化分开，实际运行三次 8 维潜空间 NSGA-II 搜索，获得 163 个近似 Pareto 候选。

不同偏好下的决策体现目标感官接近度、化学画像改动与相对缺陷指标之间的取舍。数值约束及代理模型结果仅用于计算机筛选，不替代加标品评或酿造验证。本文的改进首先在于验证隔离、证据标注与可追溯决策，不以增加算法数量代替性能和实验依据。

关键词：嵌套验证；条件重要性；稳定性选择；条件生成；Pareto 决策

目录

一、 问题重述 1
1.1 问题背景 1
1.2 问题提出 1
二、 问题分析 1
三、 模型假设与符号说明 1
3.1 模型基本假设 1
3.2 符号说明 2
四、 数据预处理 2
4.1 指标选取 2
4.2 数据清洗 2
五、 模型建立与求解 3
5.1 问题一模型建立与求解 3
5.1.1 问题一求解思路 3
5.1.2 问题一模型建立 3
5.1.3 问题一模型求解与分析 4
5.2 问题二模型建立与求解 4
5.2.1 问题二求解思路 4
5.2.2 问题二模型建立 5
5.2.3 问题二模型求解与分析 5
5.3 问题三模型建立与求解 6
5.3.1 问题三求解思路 6
5.3.2 问题三模型建立 6
5.3.3 问题三模型求解与分析 7
六、 模型分析检验 9
6.1 灵敏度分析 9
6.2 误差分析 9
七、 模型评价与推广 10
7.1 模型的优点 10
7.2 模型的不足 10
7.3 模型的推广 10
参考文献 11

一、 问题重述

1.1 问题背景

赛题要求由化学谱预测感官评分、识别各感官属性 Top-3 因素，以及在风格条件下生成化学谱并完成缺陷不恶化的迁移。本文保留外部数据修订版的数据对齐和风格语义映射，并在其基础上重新实现可被文献支持的验证与优化模块。三问之间传递的是预测模型及候选证据，不是已经验证的因果关系。

用户提供方法稿[1]强调折内尺度处理、重复底值状态与约束证据分层；Schreurs 等[2]在真实商业啤酒上比较多类模型并开展加标品评。本文进一步参考模型选择偏差[3]、条件重要性[4]、稳定性选择[5]、条件生成[6]和 NSGA-II[7]，分别改善统计验证、解释可靠性及决策透明度。

原稿[2]的 175/75 分层训练测试及五折选参，与本文重复嵌套验证不同；其盲评加标结果是该研究自身的实验，不能作为本文候选产品已经改善的证据。[1]为用户提供的方法稿，未核实其作者和公开发表状态，本研究不把它等同于已同行评审成果，也不搬用其数值。

1.2 问题提出

问题一：利用化学与理化测量预测 50 项感官响应，并在评分锚点不足时提供明确标注的相对等级。

问题二：结合共表达网络筛选各感官属性的 Top-3 单项化学候选，并检验相关变量归因及名单稳定性。

问题三：在风格条件下生成化学画像，实现受约束跨风格迁移，并通过 Pareto 集合分析多目标取舍。

二、 问题分析

问题一的主要困难是样本量小、输入相关且量纲不统一。模型选择应隔离于最终误差评价，输出相对等级时不能把空白评分卡当作绝对评分标签。

问题二需要区分预测关联、名单稳定性和因果作用。相关化合物可能互相替代，因此除固定 Top-3 外，还需要条件置换与子抽样诊断。

问题三同时涉及生成分布、源样品改变和缺陷约束。第一问的代理误差会传递到迁移评价，故将尺度证据、约束可行性与真实品评效果分开讨论。

三、 模型假设与符号说明

3.1 模型基本假设

同一 beer 编号代表同一款测量样品，化学与感官数据按该键对齐；风格标签一致性由输入数据核对。

训练与验证划分评价当前附件总体内的插值能力，不预设其能够外推到新酒厂、新批次或未见风格。

秩正态变换、近邻条件置换及风格收缩分布是统计建模假设，不赋予未知化学列确定的物理含义。

感官代理及 Pareto 候选用于筛选后续实验对象，不等同于已经完成真实加标、盲评或酿造验证。

3.2 符号说明

表 1 符号说明

符号	含义	单位或范围
X	化学与理化输入矩阵	250×231，附件分析尺度
Y	感官响应矩阵	250×50，标准化值
s	风格标签	22 类
z	条件 VAE 潜变量	8 维，无量纲
pi	子样本入选频率	0 至 1
f1 f2 f3	感官偏差、改动与缺陷指标	均取最小值

四、 数据预处理

4.1 指标选取

表 2 数据与分析角色

来源	规模	角色
附件 1 与 4	250 款、231 特征、50 响应	按唯一 beer 连接并核对风格
附件 2	231 维相关结构摘要	固定网络先验，非独立新样本
附件 3	空白评分卡及汇总	定义评分维度，不能从缓存零造标签
附件 8	70 列有可比标定	逐元素尺度与单位证据
外部数据	5558 款、1498 个酒厂	评论词频和风格背景，不与专业标签拼接

主数据有 187 个完整案例，其他样本保留并在训练折内插补。输入以 SHA256 固定。未把同一啤酒的 50 个感官维度视为 50 个独立样本，也未以发生精度损失的长商品编号强行匹配外部产品。

4.2 数据清洗

对每个有标定的字段，在参考浓度为正且双方非缺失的行上，逐一比较恒等、常用对数及自然对数关系。只有至少五个可比行且全部误差不超过 1e-6，才记为正值行已核实；中位数误差接近零不能掩盖少量不一致。该证据不覆盖零值替代机制，也不证明不同版本数据完全一致。

表 3 四类缺陷的尺度证据

字段	候选变换	不一致条数	本次约束口径
DMS	log10	0	正值域浓度及阈值
X2.3.butanedione	raw	3	仅附件分析值非恶化
X4VG	log10	0	正值域浓度及阈值
X.E..2.nonenal	raw	2	仅附件分析值非恶化

DMS 和 4VG 的可比正值支持 log10 转换；双乙酰和反式 2 壬烯醛虽多数支持原值口径，却存在局部不一致，本次不以“多数一致”宣称全部物理浓度已验证。后两项继续采用附件值非增加约束，不对其未知或未完全核实尺度作完整化学阈值保证。DMS 的 17.25 μg/L 和 4VG 的 0.206333333 mg/L 来自附件参考表，属于风味参考值，不是法定安全限值。

参考[1]第 5 页，显式 NA 以训练中位数插补并附缺失标记；当某列训练最小值至少重复三次时，另构造底值状态标记。重复最低值不是已知仪器检出限，不随机抖动也不直接当作真实浓度。验证样本只按训练规则变换，不能重新估计中位数、底值或经验分布。

秩正态候选使用训练经验中秩 u=(小于当前值的个数+等于值的个数/2)/训练非缺失数，并以 1/(2n)截断概率后映射到标准正态分位。它是一种稳健预测尺度，不是对全部字段重复施加化学对数。

五、 模型建立与求解

5.1 问题一模型建立与求解

5.1.1 问题一求解思路

先在训练折内建立缺失与底值状态，再比较稳健线性和树模型候选；用内层选型、外层评价控制选择偏差，最后给出连续感官预测及相对等级。

5.1.2 问题一模型建立

候选预先固定为均值、3 或 8 成分的秩正态 PLS、秩正态 Ridge、随机森林和极端随机树。PLS 在相关响应间共享低维结构；两个树模型各 160 棵，分别使用最小叶样本 3 和 2、平方根特征抽样。Ridge 强度固定 1000。所有候选均保留 NA 和重复底值状态，PLS 与 Ridge 另执行训练内标准化。

根据[3]，选择模型本身属于训练。外层按风格分三折、使用 42、1024 和 2024 三个种子重复，内层在外层训练集上打乱三折比较多响应均方误差。内层采用普通 K 折，是因为稀有风格进一步划分后可能不足三例。每次内层拟合都独立重建预处理；外层响应不参与选型。最终评价对象是这套预声明选型程序。

每个重复拼接完整的 250 行折外预测后，按各感官目标计算 R^2、MAE 和 Spearman，再跨目标与重复汇总。折间结果、逐目标结果及各外层内层选择明细均保存。跨重复标准差只描述划分波动，不是九个独立试验的置信区间。

5.1.3 问题一模型求解与分析

表 4 同划分外层折外预测结果

程序	R^2	MAE	Spearman
FixedRandomForest	0.1966	0.3567	0.4012
NestedSelected	0.2113	0.3547	0.3970

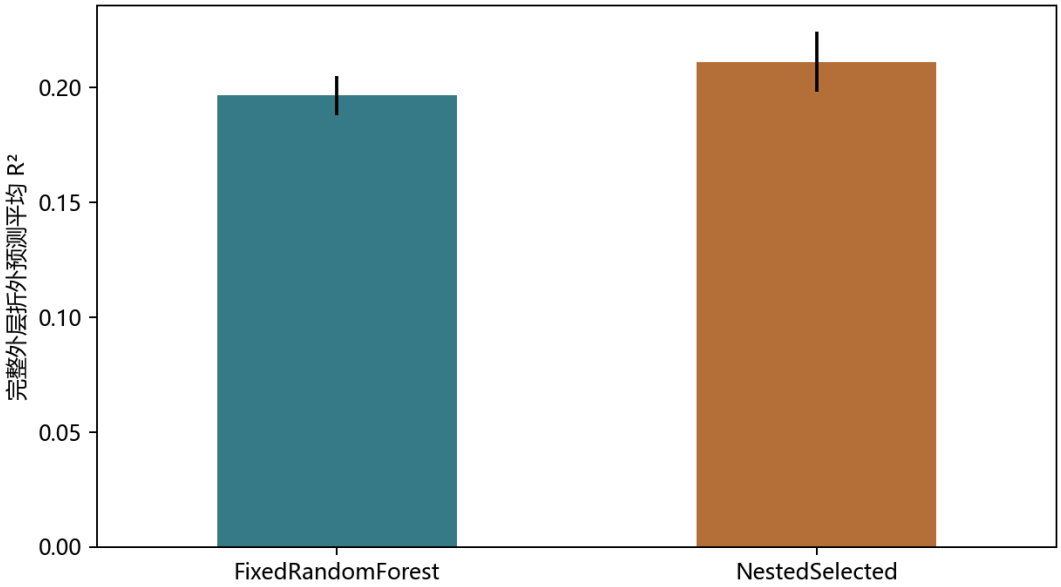


图 1 选型程序与固定随机森林的重复外层折外表现

本次嵌套程序相对固定随机森林的平均 R^2差为 0.0148。该差异来自同划分的两套程序，但本研究没有据此进行未经设计的显著性宣称。原修订版固定模型比较中随机森林折均 R^2为 0.2024，其汇总尺度和本次完整 OOF 汇总不同，不能直接把两者之差全归因于算法提高。

表 5 外层训练内部选择次数

候选	次数
RankPLS8	5
RankRidge	4

附件 4 是标准化连续响应，评分卡不提供原始逐人 0 至 6 校准锚点。因此论文首先报告连续响应的可检验误差，再输出训练响应经验分位划成七档的相对等级。全样本拟合表只用于描述已知样品，不用拟合等级一致率证明绝对评分恢复。后续真实品评应记录原始逐人评分及标准化参数。

50 个属性中有 49 个的重复外层平均 R^2大于零，stale_hops 为 0.0485。尤其第三问使用感官代理作为约束时，必须同时公开该属性的泛化能力；数值不恶化不等于真实品评不恶化。

5.2 问题二模型建立与求解

5.2.1 问题二求解思路

原修订版融合风格控制残差相关、Ridge 系数与逐属性树重要性，且 Top-3 来自不同图社区。本次保留该表及原 Bootstrap 结果；参考[1]排除 13 项宏观与派生汇总量，在 218 项单项化学候选内新增秩正态风格残差关联选择器。第一问预测仍可使用全部 231

项信息，但不能把糖类总量或派生酯类汇总冒充可直接干预的单一分子。新选择器用于诊断对照，不宣称自动优于原三证据融合。

新选择器与原三方法 Top-3 的逐属性平均 Jaccard 为 0.1040。名单变化提示选择规则敏感，不能仅因更换选择器后频率提高便称化学机制更可靠。固定附件网络仍来自全样本摘要，所以所有结果均条件于该图，未构成独立网络验证。

5.2.2 问题二模型建立

Strobl 等[4]指出，在相关预测变量上，普通随机置换可能破坏协变量依赖并扭曲重要性。本次只用每个训练折选择 Top-3 及至多五个绝对相关大于等于 0.3 的上下文变量，再在验证特征的上下文空间寻找八个近邻供体，整体替换该分子的原值，由管线重算其 NA 和底值状态。

分别进行三次局部供体置换及普通置换，计算逐目标 MSE 相对未置换预测的增量，并保留负值。供体选择不读取验证响应。该近邻方法是本地条件分布的近似，不是[4]按树切点分组的精确实现，不能当作条件随机化检验或因果效应。

参考[5]，重复 100 次在各风格内无放回抽取约一半样本，稀有风格至少保留一个，每次重估插补、经验秩、风格残差与 Top-3。它与原有有放回 Bootstrap 不同。由于逐风格取整，样本数并非严格总样本的一半；故这里只借鉴子样本选择概率思想，不套用其原理论的误选数界。

5.2.3 问题二模型求解与分析

表 6 条件与普通置换的描述性结果

指标	结果
目标化合物组合数	376
条件置换平均 MSE 增量	0.0001
普通置换平均 MSE 增量	0.0004
条件增量为负的组合数	173

新诊断 Top-3 平均频率为 0.2670，达到 0.8 的条目为 4/150；有限重复的最坏 Monte Carlo 标准误约 0.0500。频率只反映当前样本、固定图和选型规则的稳定性，不是化合物为真因子的概率。

表 7 代表属性的诊断 Top-3 及半样本频率

属性	候选及频率
A_esters_all	isopentyl_acetate (0.45)；neryl.propanoate (0.27)；phenethyl_alcohol (0.22)
F_hops_all	ethyl_octanoate (0.40)；ethyl_decanoate (0.24)；octyl_acetate (0.18)
dms	X.Z..dihydro.apofarnesal (0.25)；E.nerolidol (0.12)；X2.undecanone (0.26)
stale_hops	n.nonanol (0.31)；linalool.isovalerate (0.27)；alloaromadendrene.epoxide (0.13)
overall	X.E.E..2.4.decadienal (0.18)；cis.linalool.oxide (0.19)；linalool.isovalerate (0.28)

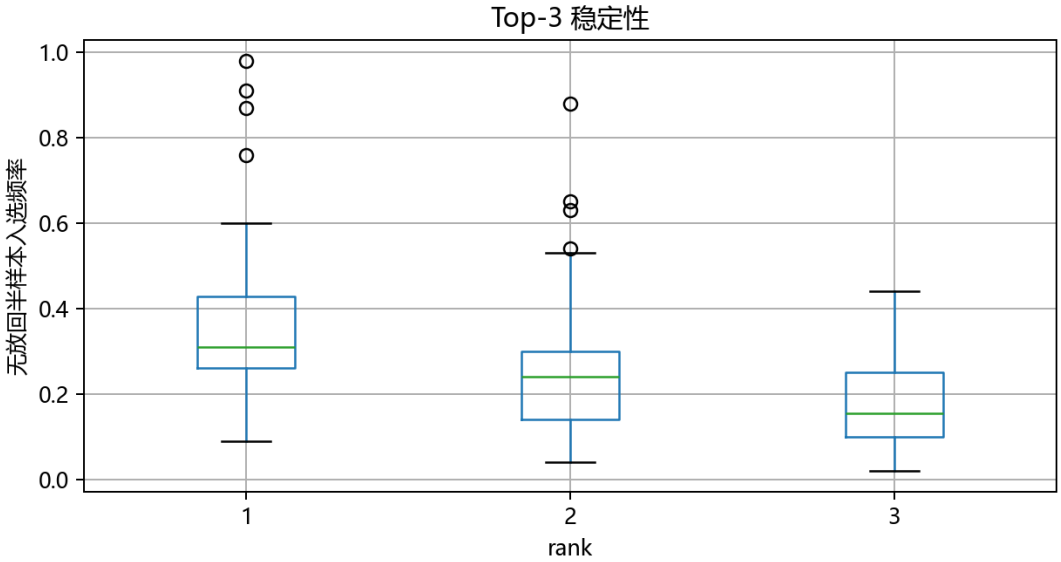


图 2 无放回半样本诊断的入选频率

5.3 问题三模型建立与求解

5.3.1 问题三求解思路

对固定条件 VAE 的采样方式进行诊断，并用独立分层留出检验比较条件收缩高斯和经验基准；在潜空间中用 NSGA-II 搜索可行候选，再进行偏好后置决策。

5.3.2 问题三模型建立

复用外部数据修订版已保存的 8 维条件 VAE 和其插补、标准化参数。编码器以化学谱和风格输出 mu 及 logvar，解码器以潜变量和风格输出化学画像。与[6]一般的条件先验网络不同，原模型 KL 项使用标准正态先验；拼接风格本身不能被写成已学习条件先验。

本次不重新训练 cVAE，使用限制可加载类型的 NumPy 推理器读取项目自身的 float32 权重，计算确定性线性层和 ReLU。原模型完整数据重构仅为训练内诊断；没有把它称为留出验证。原修订版三折 cVAE 留出误差较大，仍保留作为当前生成器泛化不足的证据。

根据[6]的重参数化形式，新增 z=mu+exp(logvar/2)*epsilon，与原有后验均值加固定 0.2 噪声及标准正态采样并列。前者反映已学习编码后验的不确定性，后两者分别是经验扰动及先验对照；任一方式都不能仅凭高风格识别率证明分布真实。

借鉴[1]第 21 至 23 页，在每个外层训练集用共同经验中秩构造正态得分，先减去各风格均值再用 LedoitWolf 估计共享组内协方差。风格中心按 n/(n+3)向全局中心收缩，参数 3 与共享协方差事先固定，本次没有复现[1]完整超参数网格。

将 Tripel、Kriek 和 Lambic 的留出样本与条件高斯生成、无条件高斯及风格内训练谱重采样比较。评价为 231 个正态得分边缘的平均 Wasserstein 距离；它衡量边缘而非联合分布，不能证明消费者喜好或物理可酿造性。所有边缘和协方差均由对应训练折拟合。

以真实源样品 beer=218 从 Pils/Lager 迁移到 Tripel 为演示，在固定解码器的 8 维潜空间搜索。潜变量边界覆盖源后验与目标风格中心附近两个经验标准差；解码输出限制到训练各列经验范围，再施加缺陷修正。该候选族是化学分析谱，不是配方，经验边界也不证明联合物理可行。

DMS 采用正浓度口径，数值上限制为不超过参考阈值和源值的 0.95 倍。4VG 虽在正标定行支持 log10 变换，但本次源样品的参考标定为零，附件记录的是底值，不能把其指数值当作已核实源浓度；因此 4VG 源非恶化与双乙酰、反式 2 壬烯醛一样只解释为分析尺度限制。4VG 阈值比较是变换假设下的数值检查，不是源浓度或真实风味保证。stale_hops 由第一问新代理预测，候选不得高于同一代理对源样品的预测。

5.3.3 问题三模型求解与分析

表 8 固定 cVAE 的内部采样诊断

采样	风格一致率	秩空间方差	最近真实谱 RMS
posterior_mean_noise	0.8871	1.0491	0.9064
posterior_reparameterized	0.9030	0.9675	0.8530
standard_normal_prior	0.2106	1.0866	1.2623

每种风格各生成 60 条并记录最近真实样品距离与近重复率。方差为组内诊断平均，不能与包含风格间差异的总体方差混称。生成谱明确带 generated_style 标识；它们是模型输出，不是新增观测，未被回灌为第一问监督标签。

表 9 三折留出平均边缘距离

模型	W1 越小越好
ConditionalRankGaussian	0.5380
StyleResampling	0.5128
UnconditionalRankGaussian	0.6627

无论哪一种方法数值最优，均完整保留经验重采样基准。复制训练样品可能在边缘距离上表现较好，但新颖性有限；模型需要同时报告分布接近程度和与真实样品的距离，不能删除强基准突出新方法。

表 10 最小化目标

目标	定义	限定
f1	50 维标准化感官偏差平方的均值	与目标风格实测均值比较，包含代理误差
f2	相对源画像的标准化 RMS 改变量	改动代理，非财务或工艺成本
f3	四项缺陷指标相对源值比的均值	DMS 浓度比加三项分析指标比，不是毒理风险

依据[7]实现非支配排序、目标空间拥挤距离、父子代精英保留、模拟二进制交叉和多项式变异。约束支配使可行解先于不可行解，不可行者按违例大小比较。种群 80，每种种子 42、43、44 固定运行 80 代，合并三次可行解后重新计算非支配关系。固定代数结束不等于证明收敛或全球最优。

本次实际执行的是 Python 实现，未安装 MATLAB，不能把这些数值称作 MATLAB gamultiobj 结果。算法先通过具有已知解析前沿的 ZDT1 收敛检查及可行性优先的构造样例，再逐项复核本题候选的原始缺陷指标与感官代理非恶化。

表 11 三次求解记录

随机种子	可行前沿数	停止原因
42	80	80 代预算结束
43	80	80 代预算结束
44	80	80 代预算结束

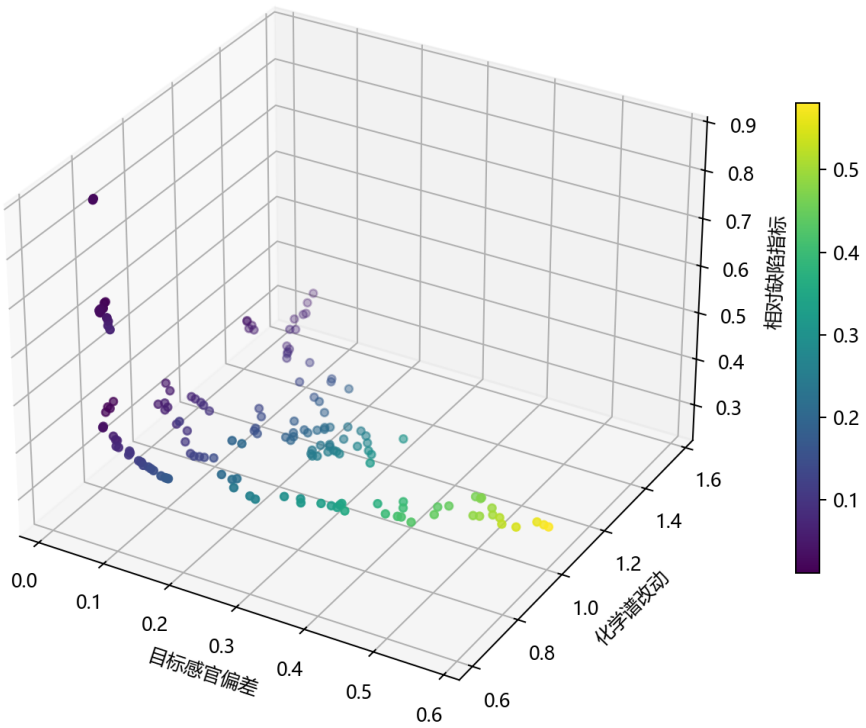


图 3 三次潜空间 NSGA-II 合并后的近似 Pareto 集合

六、 模型分析检验

6.1 灵敏度分析

先保留 Pareto 集合，再按其各目标范围归一化，恒定目标不参与距离。采用加权 TOPSIS 比较到理想点与最差点的距离；均衡、感官优先、少改动和低缺陷场景的权重分别为等权、0.6/0.2/0.2、0.2/0.6/0.2 和 0.2/0.2/0.6。权重为演示偏好，尚不是团队正式决策。

表 12 四种偏好下的候选选择

偏好	前沿编号	f1	f2	f3
balanced	37	0.0362	0.7185	0.4049
sensory_first	36	0.0355	0.7192	0.4049
small_change	85	0.0758	0.6680	0.4049
low_defect	17	0.1196	0.8494	0.3272

不同偏好可以指向同一候选，也可以产生不同取舍；单一推荐不是客观唯一最优。推荐表需要连同化学画像、感官代理、源编号和证据等级一起审阅。严禁把没有满足代理约束的候选通过放宽条件伪装成合格；若没有可行前沿，程序停止并报告失败。

6.2 误差分析

保留外部修订版的 5558 款评论汇总与三张词典工作表。外部 key 不是题目 beer 编号，未建立产品一一对应；消费者词频和专业感官 z 分数通过显式风格及九个粗粒度属性对齐，只能用于趋势一致性。本文不以外部数据调节第一问选型或迁移权重。

原外部评分关联实验按酒厂分五折验证，以避免同酒厂产品同时进入训练和测试。该部分未因本次文献修订重新训练，保留原结果与原版本标识，不把旧生成谱的外部一致性冒充新后验采样表现。评论词频与消费者评分来自同一评论环境，仍可能存在同源与高分样本选择偏差。

表 13 沿用原版的分酒厂消费者评分关联

模型	折外 R^2	MAE
Style_ABV	0.5790	0.2098
Style_ABV_Flavors	0.6361	0.1958

表 14 本次生成代理与外部画像的风格级相关

维度	实测对外部	新生成代理对外部
Body	0.2971	0.3265
Alcohol	0.5029	0.4941
Bitter	0.4471	0.4735
Sweet	0.5824	0.5647
Sour	0.7618	0.7147
Fruits	0.7118	0.6676
Hoppy	0.2529	0.3088
Spices	0.5500	0.5853
Malty	0.4588	0.4382

此处新生成画像由本次后验重参数化样品和新感官代理重新计算。相关系数是按显式对应风格聚合后的生态层面描述，不是产品级化学验证；没有对这九个维度进行选择性显著性报告。

七、 模型评价与推广

7.1 模型的优点

模型将专业评分、评论词频及化学尺度分别处理，使用重复嵌套验证评价完整选型程序，公开逐属性误差、条件重要性和子样本稳定性。约束迁移保留多目标取舍，使不同偏好可以对应不同候选，而不以单一总分掩盖差异。

7.2 模型的不足

样本仍小且缺少新酒厂或新批次独立测试；重复嵌套验证只评价当前附件总体。半样本选择不满足原稳定性选择理论全部假设，不能给出 FDR/PFER 保证。近邻置换不是精确条件检验。固定 VAE 来自完整数据，其内部采样质量不能当成新的留出泛化。单一源样品和一个目标风格的 Pareto 结果不能外推到所有迁移对。

双乙酰和反式 2 壬烯醛的局部标定差异、重复底值机制、未知尺度及缺少工艺变量均限制物理解释。派生总量和非线性基质作用没有完全纳入约束；陈旧酒花约束依赖预测较弱的代理。当前结果适合筛选实验候选，不支持可酿造、可销售或盲评偏好已改善的声明。

7.3 模型的推广

参考[2]的加标对照思路，后续应先核实化合物单位、批次和完整浓度，选择有限的 Pareto 候选，设置同批次未加标对照；随机化顺序、盲法编码、暗色容器及一致开瓶操作，记录逐位品评员原始 0 至 6 评分、方向差异与偏好。该段是待执行实验方案，不列为本研究已完成实验。

对候选的工艺可实现性，应补充原料、发酵条件、组分耦合、总量关系与干预成本，先完成小规模加标或试酿，再对真实感官和缺陷响应作独立检验。若实测与代理冲突，应更新代理与约束，而不是只保留符合模型预期的样品。

本研究以七篇来源为依据，对外部数据修订版的验证、解释与决策流程进行了可复现修改。第一问完整嵌套选型的折外 R^2为 0.2113；第二问以条件置换和半样本频率揭示名单敏感性；第三问分别报告固定 cVAE 采样、条件高斯留出分布以及潜空间 Pareto 搜索，不混同三者的验证层次。

论文的可交付价值是可追溯的模型比较、证据分级和候选选择，而不是未经品评证实的产品改良。后续应优先取得独立化学感官配对样本、原始评分与标定数据，再扩大迁移对象和工艺变量范围。

参考文献

[1] 作者未在所提供稿件首页标明. 啤酒风味预测与约束迁移. 用户提供本地 PDF，共 44 页；不视作已同行评审发表论文, 2026.

[2] Schreurs M, Piampongsant S, Roncoroni M, et al.. Predicting and improving complex beer flavor through machine learning. Nature Communications 15, 2368, 2024. DOI: 10.1038/s41467-024-46346-0.

[3] Cawley G C, Talbot N L C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. Journal of Machine Learning Research 11, 2079-2107, 2010. https://jmlr.org/papers/v11/cawley10a.html.

[4] Strobl C, Boulesteix A L, Kneib T, Augustin T, Zeileis A. Conditional variable importance for random forests. BMC Bioinformatics 9, 307, 2008. DOI: 10.1186/1471-2105-9-307.

[5] Meinshausen N, Bühlmann P. Stability selection. Journal of the Royal Statistical Society Series B 72(4), 417-473, 2010. DOI: 10.1111/j.1467-9868.2010.00740.x.

[6] Sohn K, Lee H, Yan X. Learning Structured Output Representation using Deep Conditional Generative Models. Advances in Neural Information Processing Systems 28, 3483-3491, 2015. https://papers.nips.cc/paper_files/paper/2015/hash/8d55a249e6baa5c06772297520da2051-Abstract.html.

[7] Deb K, Pratap A, Agarwal S, Meyarivan T. A Fast and Elitist Multiobjective Genetic Algorithm: NSGA-II. IEEE Transactions on Evolutionary Computation 6(2), 182-197, 2002. DOI: 10.1109/4235.996017.

[8] 2026 年 MathorCup 大数据竞赛赛道 A 题面及附件 1 至 8. 用户提供的本地材料, 2026.

[9] sp1222 / stephenpolozoff. Beer Information Tasting Profiles. Kaggle. https://www.kaggle.com/datasets/stephenpolozoff/top-beer-information . 外部文件由用户提供，平台资料访问日期 2026-10-28.